

期中專題-下雨預測

交通部中央氣象署網站

Catalog

- Get Data
 - One Year Dataset
 - JSON Data Analysis
 - JSON Data Process
 - CWA API
- Models
 - Naïve Bayes
 - SVM
 - Decision Tree
 - Random Forest & XGBoost
 - Hist Gradient Boost
- Result
 - Three City Rain Prediction
- Team Work
 - Comment

Get Data

過去氣象觀測(一年觀測資料)


"DateTime": "2024-10-31T03:00:00+08:00",
"AirPressure": "1000.4",
"AirTemperature": "24.2",
"RelativeHumidity": "94",
"WindSpeed": "14.7",
"WindDirection": "東北,NE",
"Precipitation": "3.5",
"SunshineDuration": null

Station Name	Air Pressure	Air Temperature	Relative Humid	Wind Speed	Wind Direction	Precipitation	Sunshine Du	Year	Month	Day	Hour
臺南	1005.1	32.1	65	2.1	西北,NW	0	0.5	2024	6	7	12
臺南	1004.6	31.5	70	5.1	西北,NW	0	0.8	2024	6	7	13
臺南	1004.4	31.3	70	3.9	西北西,WNW	0	1	2024	6	7	14
臺南	1003.7	30.8	70	2.6	西北西,WNW	0	0.9	2024	6	7	15
臺南	1003.5	30.1	71	2.8	西北,NW	0	0.5	2024	6	7	16
臺南	1003.8	30.1	72	2.2	北北西,NNW	0	0.3	2024	6	7	17
臺南	1004.1	29	75	3.5	西北,NW	0	0.4	2024	6	7	18
臺南	1004.8	28.2	79	2.8	北北西,NNW	0	0	2024	6	7	19
臺南	1005.5	27.4	83	3.7	北,N	0	0.28	2024	6	7	20
臺南	1005.9	27.5	84	2.9	北,N	0	0.28	2024	6	7	21

一年觀測資料-地面測站觀測資料

資料集		資料範例
一年觀測資料-地面測站觀測資料		
檔案下載	JSON XML	
資料集類型	rawData	
資料集描述	地面測站觀測資料-地面測站觀測資料	
主要欄位說明	站碼、日期、測站氣壓、溫度、相對溼度、風速風向、降水量、日照時數	
資料集提供機關	中央氣象署	
更新頻率	1天	
授權方式	氣象資料開放平臺使用規範	
授權說明網址	https://opendata.cwa.gov.tw/about/rules	
計費方式	免費	
編碼格式	UTF-8	
資料集提供機關聯絡人	胡先生	
資料集提供機關聯絡人電話	02-23491034	
備註(說明資料)	無	

JSON Data Analysis



JSON Data Process

定位到 Location (List)

將需要的資料填入至DataFrame

```
weather_elements = obs_time.get('weatherElements', {})  
row = {  
    "StationName"      : station_name,  
    "DateTime"         : datetime_value,  
    "AirPressure"       : weather_elements.get("AirPressure"),  
    "AirTemperature"    : weather_elements.get("AirTemperature"),  
    "RelativeHumidity"   : weather_elements.get("RelativeHumidity"),  
    "WindSpeed"         : weather_elements.get("WindSpeed"),  
    "WindDirection"     : weather_elements.get("WindDirection"),  
    "Precipitation"     : weather_elements.get("Precipitation"),  
    "SunshineDuration"  : weather_elements.get("SunshineDuration"),  
}  
data_list.append(row)
```

將其json資料摘取氣候訊息寫成dictionary型式
再集成成DataFrame，並存成CSV檔案作為資料集



一年氣候觀測資料總計 237816 筆

降雨量資料處理：

```
df['Precipitation'] = df['Precipitation'].replace({'T': 0.2})  
df['Precipitation'] = pd.to_numeric(df['Precipitation'], errors='coerce')  
df['Precipitation'] = df['Precipitation'].fillna(0)
```

以0.2填補 T 標示的降雨量(降水量小於0.5mm)
並將其他標示為故障或式缺失的資料填補 0

缺失值 (not available) 問題

蘭嶼	977.8	20.4	98.0	22.7	北北東,NNE	2.5
蘭嶼	978.4	20.3	98.0	24.5	北北東,NNE	0.5
蘭嶼	978.6	20.1	99.0	25.4	北北東,NNE	2.5
蘭嶼	978.0			28.0	北北東,NNE	2.0
蘭嶼	979.3			23.2	北北東,NNE	3.5
蘭嶼	978.7			19.8	北北東,NNE	4.0
蘭嶼	979.1			15.8	北北東,NNE	4.0

程式填補資料缺失：

```
# 將欄位的資料轉換為數值型別  
df['AirPressure'] = pd.to_numeric(df['AirPressure'], errors='coerce')  
df['AirTemperature'] = pd.to_numeric(df['AirTemperature'], errors='coerce')  
df['RelativeHumidity'] = pd.to_numeric(df['RelativeHumidity'], errors='coerce')  
df['WindSpeed'] = pd.to_numeric(df['WindSpeed'], errors='coerce')  
df['SunshineDuration'] = pd.to_numeric(df['SunshineDuration'], errors='coerce')  
df['SunshineDuration'] = df['SunshineDuration'].fillna(round(df['SunshineDuration'].mean(), 2))  
  
# 使用中位數填補缺失值  
df['AirPressure'] = df['AirPressure'].fillna(df['AirPressure'].median())  
df['AirTemperature'] = df['AirTemperature'].fillna(df['AirTemperature'].median())  
df['RelativeHumidity'] = df['RelativeHumidity'].fillna(df['RelativeHumidity'].median())  
df['WindSpeed'] = df['WindSpeed'].fillna(df['WindSpeed'].median())
```

以平均值與中位數填補缺失的數值資料 NA


Get Data : CWA API

-- 用於抓取現在的氣候天氣資訊

API 使用：

```
api_key = "CWA-FF2E97A7-724C-46B0-AB6D-530F7C2FBEB6" # API 金鑰
num = 1
endpoint_url = f"https://opendata.cwa.gov.tw/api/v1/rest/\
datastore/O-A0003-001?Authorization={api_key}&format=JSON&limit={num}"
```

jsoncrack.com (JSON Data Analysis)



中央氣象署開放資料平臺
之資料擷取API

現在天氣觀測報告

現任天氣觀測報告-現任天氣觀測報告

現在天氣觀測報告-現在天氣觀測報告	
資料集	資料預覽
資料集	資料範例
檔案下載	JSON XML
資料擷取API服務說明網址	API
資料集類型	rawData
資料集描述	現在天氣觀測報告-有人氣象站資料
主要欄位說明	CoordinateFormat、CoordinateName、StationLatitude、StationLongitude、CountyCode、CountyName、StationAltitude、TownCode、TownName、DateTime、AirPressure、AirTemperature、GustInfo、WindDirection、PeakGustSpeed、WindSpeed、Precipitation、RelativeHumidity、SunshineDuration、UVI

以Python程式混整JSON資料整理成csv檔案

阿里山	陰	0.0	280.0	1.2	6.4
玉山	陰	0.0	240.0	3.0	-2.3
嘉義	多雲有霧	0.0	90.0	1.0	13.0
臺南	多雲	0.0	20.0	3.1	17.6
高雄	多雲	0.0	0.0	0.1	14.5
恆春	多雲	0.0	80.0	0.8	18.4
宜蘭	陰	0.0	260.0	1.3	15.7
花蓮	陰	0.0	240.0	3.6	17.5

Get Data : 9 Years Record XML

每月氣象-過去9年地面測站每月氣象資料

資料集	
每月氣象-過去9年地面測站每月氣象資料	
檔案下載	 ZIP
資料集類型	rawData
資料集描述	過去9年地面測站每月氣象資料-過去9年地面測站每月氣象資料
主要欄位說明	站名、站碼、日期、溫度、雨量、風速/風向、相對溼度、測站氣壓、降水日數、日照時數
資料集提供機關	中央氣象署
更新頻率	1次/年，如有資料更新不定期更新
授權方式	氣象資料開放平臺使用規範
授權說明網址	https://opendata.cwa.gov.tw/about/rules
計費方式	免費
編碼格式	UTF-8

程式處理XML檔案

```
data = {
  "StationID": station_id,
  "StationName": station_name,
  "YearMonth": year_month,
  "MeanTemperature": get_value('./ns:AirTemperature/ns:monthly/ns:Mean'),
  "MaxTemperature": get_value('./ns:AirTemperature/ns:monthly/ns:Maximum'),
  "MaxTemperatureDate": get_value('./ns:AirTemperature/ns:monthly/ns:MaximumDate'),
  "MinTemperature": get_value('./ns:AirTemperature/ns:monthly/ns:Minimum'),
  "MinTemperatureDate": get_value('./ns:AirTemperature/ns:monthly/ns:MinimumDate'),
  "AccumulatedPrecipitation": get_value('./ns:Precipitation/ns:monthly/ns:Accumulation'),
  "RainyDays": get_value('./ns:Precipitation/ns:monthly/ns:GE01Days'),
  "MaxWindSpeed": get_value('./ns:WindSpeed/ns:monthly/ns:Maximum'),
  "MaxWindSpeedDate": get_value('./ns:WindSpeed/ns:monthly/ns:MaximumDate'),
  "MaxWindDirection": get_value('./ns:WindDirection/ns:monthly/ns:Maximum'),
  "MaxGustSpeed": get_value('./ns:PeakGustSpeed/ns:monthly/ns:Maximum'),
  "MaxGustSpeedDate": get_value('./ns:PeakGustSpeed/ns:monthly/ns:MaximumDate'),
  "MaxGustDirection": get_value('./ns:PeakGustDirection/ns:monthly/ns:Maximum'),
  "MeanHumidity": get_value('./ns:RelativeHumidity/ns:monthly/ns:Mean'),
  "MinHumidity": get_value('./ns:RelativeHumidity/ns:monthly/ns:Minimum'),
  "MinHumidityDate": get_value('./ns:RelativeHumidity/ns:monthly/ns:MinimumDate'),
  "MeanAirPressure": get_value('./ns:AirPressure/ns:monthly/ns:Mean'),
  "TotalSunshineDuration": get_value('./ns:SunshineDuration/ns:monthly/ns:Total')
}
data_list.append(data)
```


CSV :



StationName	YearMonth	MeanTemperature	MaxTemperature	MinTemperature	AccumulatedPrec	RainyDays
新北	2023-06	27.5	35.7	21.8	361.5	16
淡水	2023-06	28.1	34.6	22.7	109.5	13
鞍部	2023-06	22.4	28.1	18.5	162.5	15
臺北	2023-06	28.8	36.2	22.9	482.0	13
竹子湖	2023-06	24.1	31.1	20.2	153.0	14
基隆	2023-06	28.2	35.6	23.7	135.0	12
彭佳嶼	2023-06	26.8	31.5	21.3	39.0	6
花蓮	2023-06	27.6	32.6	23.3	441.5	16

Data Process : Features Engineering

資料處理方法：



SKLearn 程式碼：

```
encoder = LabelEncoder()
df['WindDirection'] = encoder.fit_transform(df['WindDirection'])

features = ['AirPressure', 'AirTemperature', 'RelativeHumidity',
            'WindSpeed', 'WindDirection', 'SunshineDuration']
X = df[features]
scaler = StandardScaler()
df[features] = scaler.fit_transform(X)
df[features] = round(df[features],4)
```

處理後的資料
DataFrame

StationName	AirPressure	AirTemperature	RelativeHumidity	WindSpeed	WindDirection	Precipitation	SunshineDuration
新北	0.3782	-0.1561	0.838	-0.7972	0.7922	1	0.0006
新北	0.3746	-0.1166	0.6241	-0.555	0.7922	0	0.0006
新北	0.3697	-0.1758	0.9806	-0.851	1.0009	1	0.0006
新北	0.3685	-0.1956	1.0519	-0.7703	1.0009	1	0.0006
新北	0.3746	-0.1758	1.1233	-0.851	-0.0428	1	0.0006
新北	0.3782	-0.1561	1.1233	-0.8241	-0.0428	1	-0.179
新北	0.3818	-0.1364	1.1946	-1.0124	1.0009	1	-0.179
新北	0.3818	-0.0574	1.1233	-0.9586	1.0009	1	-0.179
新北	0.3843	0.0216	1.1233	-0.7434	1.0009	1	-0.179

Models : Naive Bayes

$$P(c | x) = P(x | c) * P(c) / P(x)$$



StandardScaler()


Data : 237816

Train : 60%
Test : 40%

GaussianNB()


Naive Bayes
模型測試集準確度：0.84
分類報告：

	precision	recall	f1-score	support
0	0.87	0.95	0.91	79694
1	0.49	0.26	0.34	15433
accuracy			0.84	95127
Macro avg	0.68	0.60	0.62	95127
Weighted avg	0.81	0.84	0.81	95127



Imbalanced Dataset


Naïve Bayes Classify Confusion Matrix




No Rain : $75554 / 79694 = 0.948$

Rain : $3979 / 15433 = 0.257$

Synthetic Minority Oversampling Technique




Adaptive Boosting Classifier



Models : Naive Bayes + AdaBoost

Imbalanced Data Solution with AdaBoost



```
# 計算類別權重
class_weights = compute_class_weight(class_weight='balanced', classes=np.unique(y_train), y=y_train)
class_weight_dict = {cls: weight for cls, weight in zip(np.unique(y_train), class_weights)}

# 為每個樣本生成樣本權重
sample_weights = np.array([class_weight_dict[cls] for cls in y_train])

# 使用 MultinomialNB 作為基礎模型
nb_model = MultinomialNB()


# 使用 AdaBoost 進行提升
adaboost_model = AdaBoostClassifier(base_estimator=nb_model, n_estimators=100, random_state=42)
```

Naive Bayes


模型測試集準確度：0.70

分類報告：

	precision	recall	f1-score	support
0	0.93	0.69	0.80	79694
1	0.32	0.74	0.44	15433
accuracy			0.70	95127
Macro avg	0.68	0.60	0.62	95127
Weighted avg	0.81	0.84	0.74	95127




Models : SVM




```
smote = SMOTE(random_state=42)
X_train, y_train = smote.fit_resample(X_train, y_train)
base_model = LinearSVC(random_state=42, max_iter=20000,
dual=False, class_weight='balanced')
model = CalibratedClassifierCV(base_model, method='sigmoid')
```

Confusion Matrix



ROC



SVM 模型測試集準確度: 0.72

Class 0 Recall : 0.71

Class 1 Recall : 0.80

相比起 Naive Bayes 準確與兩類別 Recall 更高更準確一些

Models : Decision Tree

定義參數範圍：

class_weight='balanced'

最大深度


max_depth_values : [2,3,5,8,10,12,15,20]

分割節點的最小樣本數

min_samples_split_values = [2, 5 ,10]

每個葉節點的最小樣本數


min_samples_leaf_values : [1, 2,5]



```
for max_depth in max_depth_values:
    for min_samples_split in min_samples_split_values:
        for min_samples_leaf in min_samples_leaf_values:
            model = DecisionTreeClassifier(max_depth=max_depth,
                                           min_samples_split=min_samples_split,
                                           min_samples_leaf=min_samples_leaf,
                                           random_state=42)

            model.fit(X_train_main, y_train_main)
            y_val_proba = model.predict_proba(X_val)[: , 1]
            fpr, tpr, _ = roc_curve(y_val, y_val_proba)
            auc_score = auc(fpr, tpr)


            # 更新最佳模型
            if auc_score > best_auc:
                best_auc = auc_score
                best_model = model
                best_params = {'max_depth': max_depth,
                              'min_samples_split': min_samples_split,
                              'min_samples_leaf': min_samples_leaf}
```



程式找出好的決策樹：

最佳參數: {'max_depth': 8, 'min_samples_split': 2, 'min_samples_leaf': 5}

graphviz 視覺化
其中一顆樹(非最佳)




最佳驗證集 AUC: 0.87

決策樹模型測試集準確度: 0.77


Class 0 Recall : 0.77

Class 1 Recall : 0.81


Models : Random Forest 、XGBoosting




SMOTE
Random Forest n_estimators=50 max_depth=50 max_leaf_nodes=50 class_weight='balanced'



Random Forest 模型測試集準確度：0.79
Recall Class 0 : 0.79
Recall Class 1 : 0.79




SMOTE
XGBClassifier n_estimators=200, max_depth=[6,7,8] subsample: [0.8, 1.0] colsample_bytree: [0.8, 0.9]
GridSearchCV



XGBoost 模型測試集準確度：0.88
Recall Class 0 : 0.92
Recall Class 1 : 0.72

Models : Hist Gradient Boosting

--魚與熊掌可兼得的模型？




	precision	recall	f1-score	support
0	0.96	0.85	0.90	79694
1	0.51	0.82	0.63	15433
accuracy			0.84	95127

HistGradientBoosting 模型測試集準確度：0.84

HistGradientBoostingClassifier

```
max_iter = 1000
max_depth = 100
max_leaf_nodes = 100
class_weight='balanced'
```



Result : Rain Predict

最終採用模型

Hist Gradient Boost

Random Forest

XGBoosting

Ensemble Voting

顯示 6 月 下雨預測結果

City	新北	新北	新北	新北	新北	新北
Day	1	1	1	1	1	1
Hour	0	1	2	3	4	5
Actual	0	1	1	1	0	0
Voting	0	1	1	0	1	0
HGB	0	1	1	1	1	1
RF	0	1	1	0	1	0
XGB	0	0	0	0	0	0

Dataset for Final Rain Predict :

City : '新北'、'臺中'、'高雄'

Month : 6 月

其餘一年的天氣觀測資料，
作為訓練資料

Test Dataset :

Total : 2160

Class 0 : 1855

Class 1 : 305

Hist Gradient Boosting

Class 0 Recall : 0.87

Class 1 Recall : 0.76

Accuracy : 0.85

Random Forest

Class 0 Recall : 0.92

Class 1 Recall : 0.67

Accuracy : 0.89

XGBoosting

Class 0 Recall : 0.97

Class 1 Recall : 0.50

Accuracy : 0.91

Ensemble Voting:

Class 0 Recall : 0.93

Class 1 Recall : 0.67

Accuracy : 0.89

Mid-Term Project

Comment

Team : 孫加恩 C112196117
(負責簡報與程式整合)

The End